

## MATERIAL E MÉTODOS

A interface foi desenvolvida utilizando a linguagem de programação C#, a IDE (Integrated Development Environment) utilizada para o desenvolvimento foi o Visual Studio 2017. A interface foi desenvolvida para resolver problemas de planejamento florestal estratégico, utilizando da programação matemática a programação inteira mista, o modelo seguiu os critérios de formulação do modelo I conforme Johnson e Scheurman (1977).

### Definindo o problema

O modelo de otimização a ser empregado para solucionar o problema de planejamento florestal espacial, é o modelo I, proposto originalmente por Kidd et al. (1966), e assim denominado por Johnson e Scheurman (1977). Com o objetivo de maximizar o Valor Presente Líquido (VPL) da floresta, a função objetivo é estabelecida da seguinte forma:

$$Max Z = \sum_{i=1}^M \sum_{j=1}^N C_{ij} X_{ij} \quad (1)$$

Sujeito a:

$$\sum_{i=1}^M \sum_{j=1}^N X_{ij} = 1 \quad (2)$$

$$\sum_{i=1}^M \sum_{j=1}^N V_{ijk} X_{ij} \geq Dmin_k \quad \forall k = (0,1..h-1) \quad (3)$$

$$\sum_{i=1}^M \sum_{j=1}^N V_{ijk} X_{ij} \leq Dmax_k \quad \forall k = (0,1..h-1) \quad (4)$$

$$V_{H(k+1)} \geq (1 - \alpha) V_{Hk} \quad \forall k = (0,1..h-1) \quad (5)$$

$$V_{H(k+1)} \leq (1 + \beta) V_{Hk} \quad \forall k = (0,1..h-1) \quad (6)$$

$$\sum_{i=1}^M \sum_{j=1}^N A_{ijk} X_{ij} \geq \frac{At}{r} (1 - \alpha) \quad \forall k = (0,1..r) \quad (7)$$

$$\sum_{i=1}^M \sum_{j=1}^N A_{ijk} X_{ij} \leq \frac{At}{r} (1 + \alpha) \quad \forall k = (0,1..r) \quad (8)$$

$$n_i x_{ij} + \sum_{i \in N_i} x_{ij} \leq n_i \quad \forall i, k. \quad (9)$$

$$X_{ij} \in \{0,1\} \quad (10)$$

$$\text{Sendo: } V_{Hk} = \sum_{i=1}^M \sum_{j=1}^N V_{ijk} X_{ij}$$

em que:

$Z$  = Valor Presente Líquido Global (R\$);  $X_{ij}$  = Variáveis de decisão, representando o  $j$ -th prescrição de manejo adotada na  $i$ -ésima UM;  $C_{ij}$  = Valor Presente Líquido de cada unidade de manejo  $i$ , gerenciada com a prescrição de manejo  $j$ ;  $M$  = Número total de unidades de manejo (UM);  $N$  = Total de prescrições de manejo para o  $i$ -th UM;  $V_{ijk}$  = Volume ( $m^3$ ) produzido no período  $k$ , através de  $i$ -th UM adotando a  $j$ -th prescrição de manejo;  $Dmin_k$  e  $Dmax_k$  são as demandas mínimas e o máximas volumétricas ( $m^3$ ), respectivamente, em cada período do horizonte de planejamento.  $n_i$  refere-se ao número de unidades de manejo adjacentes que apresentam cortes no período  $k$ .

De acordo com este modelo de programação inteira mista, (1) representa a maximização do valor presente global, sujeito as restrições de singularidade, (2,8), as produções mínimas (3), e máximas (4), em cada período do horizonte de planejamento, o controle sobre o fluxo de produção durante o horizonte de planejamento (5,6), as restrições de regulação (7,8), que permite uma variação  $\alpha$  para flexibilizar o atendimento dessa restrição. E a restrição (8), assegura que nenhuma área adjacente será cortada no mesmo período  $k$ . A restrição de adjacência por unidade (URM), proposta por Murray (1999), foi assumida para o problema.

### Representação da solução

A representação da solução é feita utilizando um vetor de tamanho  $n$ , onde  $n$  corresponde ao número de unidades de manejo do problema. Para cada posição do vetor é assinalado um número de 1 a  $j$  que corresponde ao número de prescrições. Um exemplo seja uma floresta com 5 unidades de manejo e 10 prescrições, a representação de uma solução pode ser feita da seguinte maneira :

$$V(x) = ( \begin{array}{|c|c|c|c|c|} \hline 5 & 1 & 9 & 9 & 3 \\ \hline \end{array} )$$

Onde a prescrição 5 corresponde ao manejo adotado na unidade de manejo 1 , a prescrição 1 foi adotada na unidade de manejo 2 e assim por diante até  $n$  unidades de manejo.

### Função de avaliação

A função de avaliação utilizada no problema foi a de maximização do valor presente líquido global, as penalidades impostas referem-se a variação volumétrica

acima ou abaixo da demanda estabelecida, áreas com cortes adjacentes no mesmo período, e de regulação florestal ao final do horizonte de planejamento que podem ser apresentadas abaixo:

$$f(x) = \sum_{i=1}^m \sum_{j=1}^n C_{ij} X_{ij} - \alpha (D_k - \sum_{i=1}^m \sum_{j=1}^n V_{ijk} X_{ij})^2 - \beta (\sum_{k=0}^{h-1} y_i)^2 - \gamma (R_l - \sum_{i=1}^m A_i X_{ij})^2$$

Em que :

$\alpha, \beta, \gamma$  = Coeficientes de penalidades associados a cada restrição.

$D_k$  = Demanda volumétrica no  $k$ -ésimo período do horizonte de planejamento

$R_l$  = Área regulatória

$A_i$  = Área da unidade de manejo  $i$

$y_i$  = Somatório das áreas das unidades de manejo adjacentes cortadas no mesmo período

A restrição espacial de adjacência também foi penalizada utilizando o IAC , sendo representado da seguinte forma:

$$f(x) = \sum_{i=1}^m \sum_{j=1}^n C_{ij} X_{ij} - \alpha (D_k - \sum_{i=1}^m \sum_{j=1}^n V_{ijk} X_{ij})^2 - \beta ((\sum_{i=1}^m \sum_{j=1}^n C_{ij} X_{ij}) (\frac{\sum_{k=0}^{h-1} \sum_{i=1}^m A_i^2 (\frac{1}{d_i})^2}{\sum_{i=1}^m A_i}))^2 - \gamma (R_l - \sum_{i=1}^m A_i X_{ij})^2$$

em que IAC = índice de área sem cobertura florestal,  $A_i$  = área da unidade de manejo  $i$  com intervenção, em hectares,  $d_i$  = distância ate a unidade de manejo mais próxima com intervenção, em quilômetros.

## Preparando o arquivo *Xlsx*.

A primeira planilha que devemos fornecer no arquivo *sheet* é a planilha dados, nesta planilha devemos passar algumas informações do problema como:

Tabela 1 – informações necessária para a planilha dados.

Informação	Número
Número de u.m.	91
Prescrições por u.m.	72
Idade Regulatória (anos)	6
Horizonte de planejamento (anos)	19

A segunda planilha é a da matriz de **Prescrições** que possui as informações de cadastro das unidades de manejo, na planilha do exemplo estão exemplificadas dez prescrições (j) por unidade de manejo (i) , nesta planilha estão as informações de cadastro como Talhao, Area, Idade , Regime atual, Distpatio, Declividade, MaterialGenetico, além das informações de Custos Totais, Receitas Totais, VPL , CustosColheita, CustosBaldeio, CustosTransporte, CustosSilvicultura, CustoImplantacao, custo\_ate\_ano0. As informações de custo são necessarias para gerar os graficos com os resultados e avalia los , caso não possua algum dos custos coloque o valor 0 como padrão.

Tabela 2 – Matriz com as prescrições de manejo com os custos e receitas totalizados para cada prescrição e unidade de manejo.

Talhão	Área	Idade	Regime	Distpatio	Declividade	Material Genético	Custos totais	Receitas totais	Vpl	Custos Colheita	Custos Baldeio	Custos Transporte	Custos Silvicultura	Custo Implantação	Custos ate ano0
1	2.53	6	af	5.1	12	4	52,412.4	51,869.9	-542.5	28,999.1	1,407.6	2,536.2	10,199.6	7,748.4	1,521.5
1	2.53	6	af	5.1	12	4	45,534.1	51,869.9	6,335.9	28,999.1	1,407.6	2,536.2	4,873.7	6,587.9	1,129.5
1	2.53	6	af	5.1	12	4	52,177.4	53,609.5	1,432.1	30,041.5	1,454.8	2,621.3	9,182.4	7,355.9	1,521.5
1	2.53	6	af	5.1	12	4	46,142.1	53,609.5	7,467.5	30,041.5	1,454.8	2,621.3	4,563.5	6,331.4	1,129.5
1	2.53	6	af	5.1	12	4	49,637.3	51,197.9	1,560.5	28,767.1	1,389.4	2,503.4	8,736.9	6,719.0	1,521.5
1	2.53	6	af	5.1	12	4	44,050.1	51,197.9	7,147.8	28,767.1	1,389.4	2,503.4	4,447.9	5,812.9	1,129.5
1	2.53	6	af	5.1	12	4	48,347.4	50,769.3	2,421.9	28,566.2	1,377.8	2,482.4	7,927.1	6,472.4	1,521.5
1	2.53	6	af	5.1	12	4	43,423.4	50,769.3	7,345.9	28,566.2	1,377.8	2,482.4	4,198.0	5,669.5	1,129.5
1	2.53	6	af	5.1	12	4	46,922.7	49,108.0	2,185.4	27,645.5	1,332.7	2,401.2	7,705.4	6,316.4	1,521.5
1	2.53	6	af	5.1	12	4	42,209.8	49,108.0	6,898.2	27,645.5	1,332.7	2,401.2	4,133.5	5,567.6	1,129.5

A Matriz **mCorte** é uma matriz binária que informa do ano zero ao final do horizonte de planejamento se a unidade de manejo i com a prescrição j sofreu corte (1) ou não (0) no ano k. As duas primeiras colunas são para exemplificar, e não são necessárias na montagem do arquivo

Tabela 3 – Matriz indicando possibilidades de corte para cada unidade de manejo i e prescrição j.

Talhão	Prescrição	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
1	1	1	0	0	0	1	0	0	0	1	0	0	0	1	0	0	0	1	0	0
1	2	1	0	0	0	1	0	0	0	1	0	0	0	1	0	0	0	1	0	0
1	3	1	0	0	0	0	1	0	0	0	1	0	0	0	0	1	0	0	0	1
1	4	1	0	0	0	0	1	0	0	0	1	0	0	0	0	1	0	0	0	1
1	5	1	0	0	0	0	0	1	0	0	0	1	0	0	0	0	0	1	0	0
1	6	1	0	0	0	0	0	1	0	0	0	1	0	0	0	0	0	1	0	0
1	7	1	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0	0	0	1
1	8	1	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0	0	0	1
1	9	1	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0	0	1
1	10	1	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0	0	1

A matriz obrigatoriamente deve ter o nome **mCorte** para entendimento do programa. Esta matriz auxilia na construção da restrição de volume e na restrição de adjacência, as colunas talhão e prescrição são meramente ilustrativas.

A matriz **mRegArea** contém a informação da área da unidade de manejo (i) sobre a prescrição de manejo (j) com idade residual, no problema de exemplo foi considerado uma idade regulatória de 6 anos.

Tabela 4 – Matriz com as informações de área para cada classe de idade residual.

Talhão	Prescrição	Área1	Área2	Área3	Área4	Área5	Área6
1	1	0	0	2.53	0	0	0
1	2	0	0	2.53	0	0	0
1	3	2.53	0	0	0	0	0
1	4	2.53	0	0	0	0	0
1	5	0	0	2.53	0	0	0
1	6	0	0	2.53	0	0	0
1	7	2.53	0	0	0	0	0
1	8	2.53	0	0	0	0	0
1	9	2.53	0	0	0	0	0
1	10	2.53	0	0	0	0	0

Outra matriz é a **mVolume** que fornece as informações de volume total (m³) da unidade de manejo (i) , em cada ano k do horizonte do planejamento ao assinalar ao alternativa de manejo j e pode ser exemplificada conforme tabela x

Tabela 5 – Matriz com as informações de volume total (m³) por unidade de manejo (i) e prescrição (j).

Talhão	Prescrição	0.0	1.0	2.0	3.0	4.0	5.0	6.0	7.0	8.0	9.0	10.0	11.0	12.0	13.0	14.0	15.0	16.0	17.0	18.0
1	1	610.8	0.0	0.0	0.0	610.8	0.0	0.0	0.0	610.8	0.0	0.0	0.0	610.8	0.0	0.0	0.0	610.8	0.0	0.0
1	2	610.8	0.0	0.0	0.0	610.8	0.0	0.0	0.0	610.8	0.0	0.0	0.0	610.8	0.0	0.0	0.0	610.8	0.0	0.0
1	3	610.8	0.0	0.0	0.0	0.0	809.4	0.0	0.0	0.0	610.8	0.0	0.0	0.0	0.0	809.4	0.0	0.0	0.0	610.8
1	4	610.8	0.0	0.0	0.0	0.0	809.4	0.0	0.0	0.0	610.8	0.0	0.0	0.0	0.0	809.4	0.0	0.0	0.0	610.8
1	5	610.8	0.0	0.0	0.0	0.0	0.0	988.2	0.0	0.0	0.0	610.8	0.0	0.0	0.0	0.0	0.0	988.2	0.0	0.0
1	6	610.8	0.0	0.0	0.0	0.0	0.0	988.2	0.0	0.0	0.0	610.8	0.0	0.0	0.0	0.0	0.0	988.2	0.0	0.0
1	7	610.8	0.0	0.0	0.0	0.0	0.0	0.0	1126.6	0.0	0.0	0.0	610.8	0.0	0.0	0.0	0.0	0.0	0.0	1126.6
1	8	610.8	0.0	0.0	0.0	0.0	0.0	0.0	1126.6	0.0	0.0	0.0	610.8	0.0	0.0	0.0	0.0	0.0	0.0	1126.6
1	9	610.8	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1221.7	0.0	0.0	0.0	610.8	0.0	0.0	0.0	0.0	0.0	988.2
1	10	610.8	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1221.7	0.0	0.0	0.0	610.8	0.0	0.0	0.0	0.0	0.0	988.2

A matriz **mAdj** é uma matriz binária de tamanho  $n \times n$  onde o valor 1 é assinalado se o talhão  $i$  for vizinho do talhão  $ii$  e 0 caso contrário, esta é a matriz ordinária de adjacência (MAO), ela pode ser criada com ajuda de um S.I.G, no Arcgis por exemplo existe uma função que se chama **polygonneighboord** que retorna esta matriz.

Tabela 6 – Matriz contento a informação de unidades de manejo adjacentes.

Talhão(i)	1	2	3	4	5	6	7	...	n
1	0	1	0	0	0	0	0	0	0
2	1	0	1	0	0	0	0	0	0
3	0	1	0	1	0	0	0	0	0
4	0	0	1	0	1	0	0	0	0
5	0	0	0	1	0	1	0	0	0
6	0	0	0	0	1	0	1	0	0
7	0	0	0	0	0	1	0	1	0
...	0	0	0	0	0	0	1	0	1
n	0	0	0	0	0	0	0	1	0

A matriz **mDistancia** possui as distâncias de cada unidade de manejo (i) até a unidade de manejo (ii). Como pode ser observado na tabela xx, estas distancias são utilizadas no cálculo do IAC, que pode ser utilizado como penalidade na função de avaliação.

Tabela 7 – MAtriz i com as distancias de cada unidade de manejo (i) , a unidade de manejo (ii).

Talhão(i)	ii	Distância
1	1	0.0
1	2	275.8
1	3	539.3
1	4	275.8
1	5	40.0
1	6	263.5
1	7	539.3
1	8	263.5
1	9	8.0
1	10	1202.6



Após montar este arquivo com as distâncias estamos prontos para começar o planejamento!!

Para exemplificar o uso das meta-heurísticas implementadas, utilizaremos uma fazenda modelo, denominada fazenda cajamarca, que deseja produzir madeira para uma fábrica de celulose, a empresa possui uma área de efetivo plantio de 1.892,08 ha. O horizonte de planejamento (hp), utilizado é de 18 anos, a área média de cada unidade de manejo é de 20,8 ha e o problema será manejar a floresta para a produção de madeira para celulose, sendo plantado no espaçamento 3x3, com um ciclo de dois cortes e regimes de alto-fuste (AF) e primeira talhadia para fins de estabelecer as prescrições de manejo. As rotações serão de 5 a 9 anos para ambos os regimes de corte. A idade regulatória adotada será de 6 anos.

O objetivo será maximizar o valor presente líquido durante todo o horizonte de planejamento, a uma taxa de descontos de 10% ao ano, sujeito as restrições de produção, regulação e de adjacência. A distribuição inicial das classes de idade da floresta encontra-se na Figura 1.

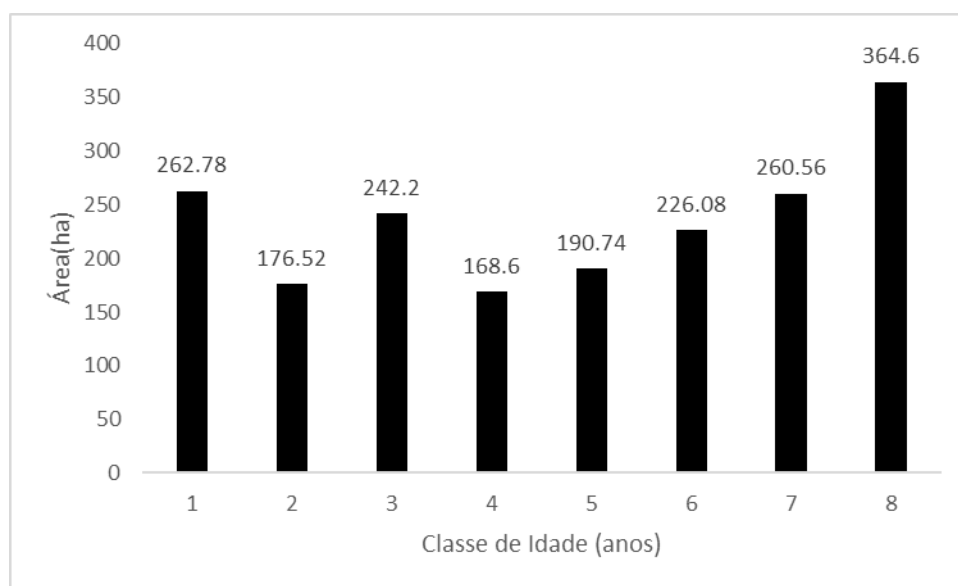


Figura 1 – Distribuição inicial de classes de idade encontrada na fazenda modelo cajamarca.

## RESULTADOS

### Iniciando a interface



Figura 2– Tela inicial do sistema.

Após preparar as planilhas com as matrizes referentes ao modelo de planejamento iniciamos a interface, a importação dos dados é feita no formato *xlsx* ou JSON, como exemplo iremos utilizar a planilha *xlsx*, clicando em “**Carregar XLSX**”, a tela para selecionarmos o arquivo contendo as planilhas descritas no item anterior é aberta, como exemplificado na Figura 3.

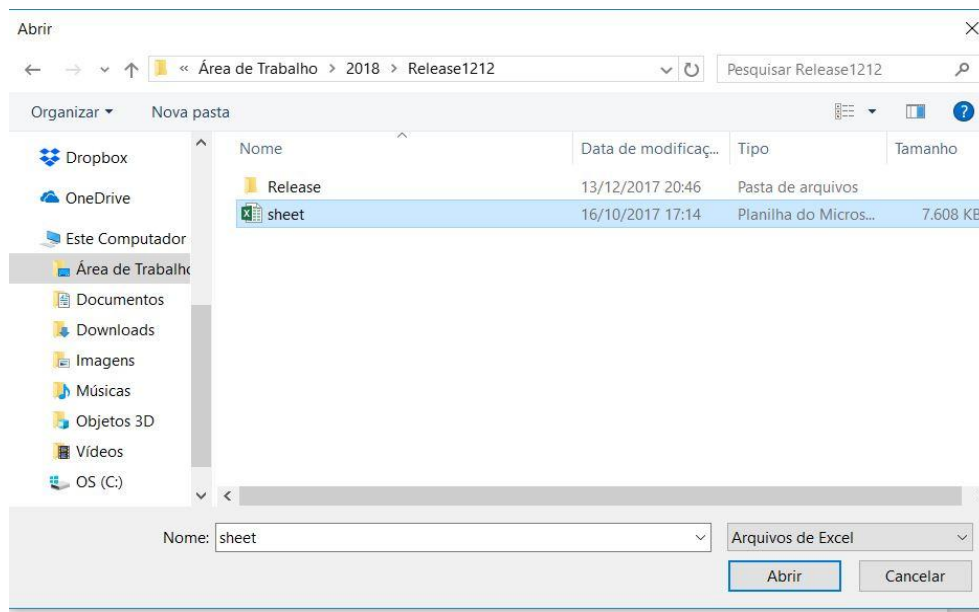


Figura 3- Selecionando o arquivo *xlsx* contendo as planilhas para resolução do problema.

Após selecionada a planilha com os dados a tela para seleção da meta-heurística a ser utilizada é apresentada, assim como as configurações dos parâmetros do problema de planejamento florestal. A Figura 4 é ilustrada a tela inicial após carregar as informações do problema.

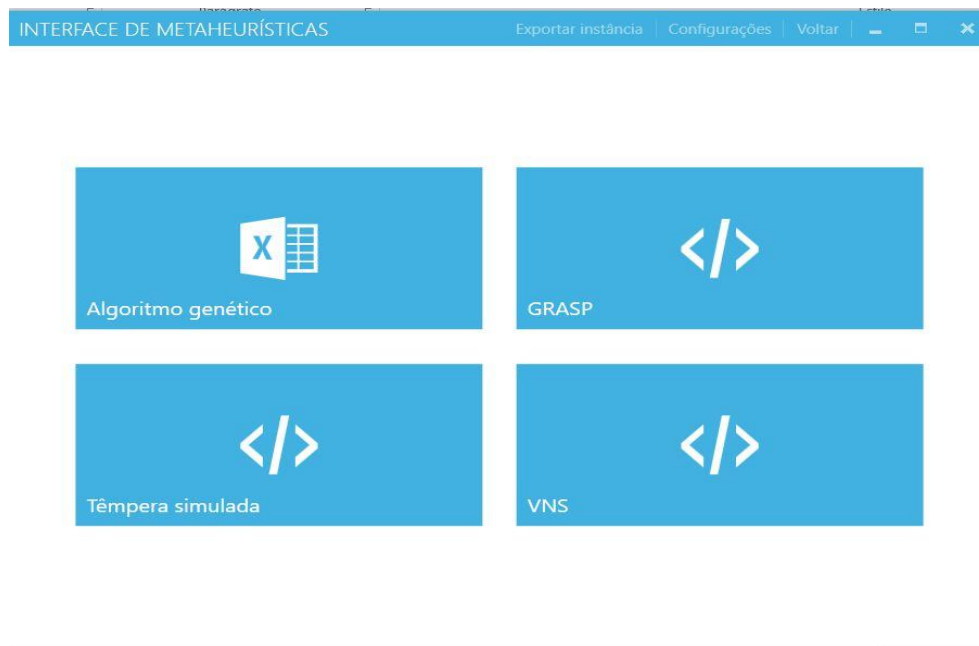


Figura 4- Tela para seleção das meta-heurísticas e configuração dos parâmetros do problema.

## Configurações

Antes de resolver os problemas utilizando as meta-heurísticas precisamos determinar algumas restrições do problema, estas restrições são determinadas nas configurações. A Figura 6 ilustra a tela inicial de configurações.

INTERFACE DE METAHEURÍSTICAS Exportar instâ

### Configurações

**Restrições do problema**

Volume mínimo	100000.00 + -
Volume máximo	200000.00 + -
% variação área	0.20000 + -
% variação volume +	0.20000 + -
% variação volume -	0.20000 + -
Restrição de adjacência	IAC ▾
Green up	1 + -

**Parâmetros da função de avaliação**

Alfa	0.000001 + -
Beta	0.000100 + -
Gama	20.000000 + -

**SALVAR**

Figura 5— Restrições do problema e parâmetros da função de avaliação.

Nas restrições devemos informar os limites de demanda (Volume mínimo e máximo) necessários de madeira, estão relacionadas as restrições 3 e 4 do modelo matemático. Outra restrição que precisa ser definida aqui é a restrição de regulação, referente as restrições 7 e 8 do modelo, que permite definir um limite de variação para a área regulatória, sendo a área total dividida pela idade regulatória, a idade regulatória deve ser informada no arquivo *xlsx*, na planilha dados. Outra informação é a restrição que volumétrica que não permite a variação do volume em anos seguidos, existe a possibilidade de colocar volumes crescentes ou decrescentes ao longo do horizonte de planejamento, conforme as restrições 5 e 6 do modelo matemático.

A restrição de adjacência pode ser utilizada de duas formas na função de avaliação como definido anteriormente o usuário tem a opção de escolher se deseja penalizar pelo somatório das áreas adjacentes com corte no mesmo período ao quadrado ou através do IAC, basta selecionar a opção desejada na em “Restrição de adjacência”.

Outra restrição que precisa ser definida é o período em que uma unidade de manejo (UM), adjacente que houve corte precisa ficar sem intervenção para conservação e manejo da vida selvagem ou *Green up*, para o exemplo utilizaremos 1 ano.

Após definir as restrições do modelo, é necessário calibrar os parâmetros da função de avaliação, estes valores são utilizados para convergência da função, o parâmetro alfa ( $\alpha$ ), relacionado com as penalidades volumétricas, beta ( $\beta$ ) com as penalidades de adjacência, sendo somada a área e gama ( $\gamma$ ) com a penalidade de área regulatória.

Após formular o problema, podemos iniciar a resolução do problema de planejamento florestal, para o exemplo, utilizaremos as seguintes configurações para o problema: Demanda mínima 100.000 m<sup>3</sup> e demanda máxima 200.000 m<sup>3</sup> de madeira, uma variação de 20% do volume colhido durante os períodos do H.P., para a restrição de regulação, foi permitido uma variação de 20% na área regulada, a idade regulatória foi de 6 anos, utilizamos o IAC para restrição de adjacência, sendo de 1 ano o período de *green up*.

Pronto agora é só **salvar** e partir para definir os parâmetros das meta-heurísticas.

## Meta-heurísticas implementadas

### 1 - Algoritmo Genético

Definidas as configurações das restrições do problema em estudo, podemos selecionar a meta-heurística de interesse, configurar os parâmetros e encontrar uma solução para o problema de planejamento florestal estratégico, iniciaremos ilustrando a meta-heurística AG, primeiramente precisamos definir os parâmetros que são ilustrados na figura 6.

Parâmetro	Valor
População inicial	20
Taxa de cruzamento	0.50000
Taxa de mutação	0.100
Número de iterações	400

INICIAR HEURISTICA

Figura 7-Parâmetros da meta-heurística Algoritmo Genético.

O Ag depende de uma população de soluções candidatas. O tamanho da população, que geralmente é um parâmetro especificado pelo usuário, é um fator importante que afeta o desempenho do AG, como exemplo, tamanho pequeno de população pode levar a uma convergência prematura e levar a soluções de baixa qualidade, por outro lado, grandes populações levam a gastos desnecessários de recursos computacionais (SASTRY et al., 2014).

Na interface a população inicial é gerada com os indivíduos que tenham a função de avaliação maior que zero, existindo um filtro inicial para gerar soluções boas, a população estará completa quando atingido o número de pais determinado pelo parâmetro população inicial, neste exemplo 20 indivíduos. Para a interface utilizamos a seleção proporcional e o método da roleta viciada para a seleção dos pais, que foi descrito no capítulo 1.

Após a seleção, os indivíduos do grupo de reprodução são recombinaados, para criar novos, e melhores descendentes. Muitos métodos de *crossover* foram projetados, a taxa de *crossover* utilizada pela interface é a de um ponto, onde a ruptura é feita a uma porcentagem determinada pelo usuário, no exemplo utilizamos uma taxa de 50 %.

Se usarmos um operador de crossover, como o crossover de um ponto, podemos talvez ter melhores cromossomos, mas o problema é, se os dois pais têm o mesmo alelo em um determinado gene, em seguida, um ponto de cruzamento não vai mudar isso. Em outras palavras, esse gene terá o mesmo alelo para sempre. A Mutação é realizada para superar este problema, a fim de acrescentar diversidade à população (SASTRY et al., 2014).

Geralmente, utilizando pequenas taxas de *crossover* e *mutação*, junto com alta taxa de seleção temos uma tendência a preservar boas soluções atuais, enquanto utilizando altas taxas de crossover e mutação, uma alta taxa de mutação e uma pequena taxa de seleção temos uma tendência a explorar novas soluções, é importante manter um equilíbrio entre esses dois aspectos em uma implementação do AG. Há também efeitos de interação entre os parâmetros, o que implica que eles não podem ser considerados separadamente (LU e ERIKSSON, 2000).

É o número de vezes que ocorrerá o processo de seleção e cruzamento dos pais.



Utilizaremos uma população inicial de 20 indivíduos, uma taxa de crossover de 50%, uma taxa de mutação de 10% e o critério de parada é o número de iterações sem melhorar a solução é de 400.

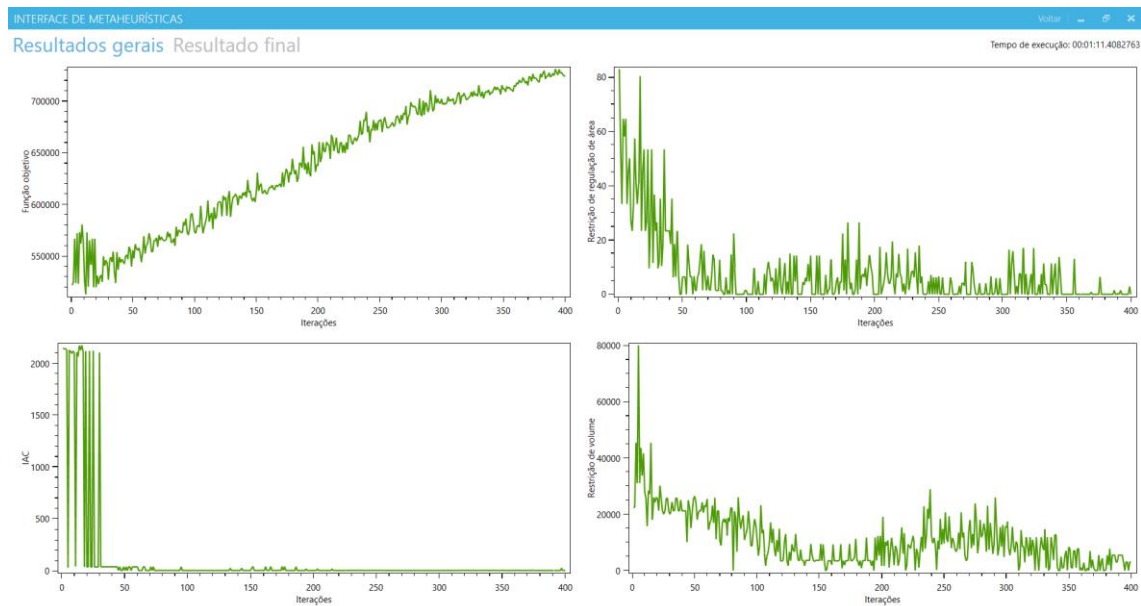


Figura 8 – Resultados gerais , função objetivo e o comportamento das penalidades de regulação , IAC e volumétrica, com o passar das iterações.



Figura 9 – Resultados finais coma área regulada, o volume e o IAC por período além do VPL acumulado.

Alguns trabalhos já foram realizados utilizando o Ag para resolução de problemas de regulação florestal, Rodrigues et al., 2004, testaram os efeitos do tamanho

da população, do método de seleção e do tipo de *crossover* para o Ag e concluíram que e os melhores métodos de seleção foram os de *Boltzmann* e escalonamento e uma população ótima de 75 a 100 indivíduos, segundo os autores o tipo de *crossover* utilizado não influenciou o resultado, Silva et al., (2009), também avaliando os parâmetros de um AG para um problema de regulação florestal, concluíram que a população é o fator que mais influencia o desempenho do AG e a taxa de *crossover* e mutação não aumentaram o desempenho do algoritmo. Outro trabalho realizado por Gomide et al., 2009, avaliaram os métodos de seleção torneio, elitista, roleta e bi-classista, e concluíram que o melhor operador de seleção testado foi o de roleta.

Binote et al., (2012), Binote et al., (2014), utilizaram o Ag para resolução de problemas de regulação florestal acrescentando restrições ambientais e sociais de caráter espacial no modelo, os parâmetros utilizados pelos autores foram, uma população de 30 indivíduos, a seleção dos indivíduos ocorreu por elitização, uma taxa de crossover de múltiplos pontos e uma taxa de mutação de 6%, o Ag foi eficiente para resolver os modelos construídos.

Assim, apesar da população ser um parâmetro crucial no desempenho do Ag, estes trabalhos apresentam tamanho de população diferente, porem sempre as maiores populações são escolhidas na avaliação.

Analisando a figura 7 e 8, observamos o valor da função de avaliação de 723816,2202 o valor da penalidade de regulação foi igual a 0 indicando que a meta-heurística conseguiu atender a restrição de regulação, já a penalidade de volume foi de 3.029,12 m<sup>3</sup>, que ocorreu do ano 2 para o ano 3 onde a variação do volume foi maior que 20% permitida, o IAC convergiu em 2,73 e o maior valor foi encontrado no ano 7.

## 2 - Greedy Randomized Adaptive Search Procedures (Procedimentos de Busca gulosos, aleatórios e adaptativo)



A interface de configuração da meta-heurística Grasp, intitulada "INTERFACE DE METAHEURÍSTICAS". No topo, há uma barra azul com o título e links para "Exportar instância", "Configurações" e "Voltar". O corpo da interface contém cinco parâmetros configuráveis:

- Alfa:** Campo de entrada com o valor "0.50" e botões de incremento (+) e decremento (-).
- Iterações da busca local:** Campo de entrada com o valor "100" e botões de incremento (+) e decremento (-).
- Iterações da fase construtiva:** Campo de entrada com o valor "50" e botões de incremento (+) e decremento (-).
- Vizinhança:** Seletor de opção com dois botões de rádio: "1-Opt" (selecionado) e "2-Opt".
- Método de escolha:** Seletor de opção com dois botões de rádio: "Cardinalidade" (selecionado) e "Valor".

Na base da interface, há um botão cinza com o texto "INICIAR HEURISTICA".

Figura 10– Parâmetros da meta-heurística *Grasp*.

- Alfa
- Iterações da busca local
- Iterações da fase construtiva
- Vizinhança

A vizinhança está relacionada a busca local que é realizada após a fase construtiva, esta pode ser feita com 1-opt, onde apenas uma posição do vetor é alterada aleatoriamente, e o 2-opt, duas posições do vetor são alteradas aleatoriamente.

- Método de escolha da LRC

O método de escolha para construir a LRC (lista restrita de candidatos), pode ser limitada pelo número de elementos (baseado em cardinalidade) ou por sua qualidade (baseada em valor). No primeiro caso, é feitos  $p$  elementos com os melhores custos incrementais, onde  $p$  é um parâmetro. Já o segundo método está associado a um parâmetro limiar  $\alpha \in [0,1]$ . A LRC é formada por todos os elementos possíveis  $e \in E$  que podem ser inseridos na solução parcial em construção sem destruir viabilidade e cuja qualidade é superior para o valor limite, isto é,  $c(e) \in [c_{\min}, c_{\min} + \alpha (c_{\max} - c_{\min})]$ . O

caso  $\alpha = 0$  corresponde a um algoritmo puro e ganancioso, enquanto  $\alpha = 1$  é equivalente a uma construção aleatória.

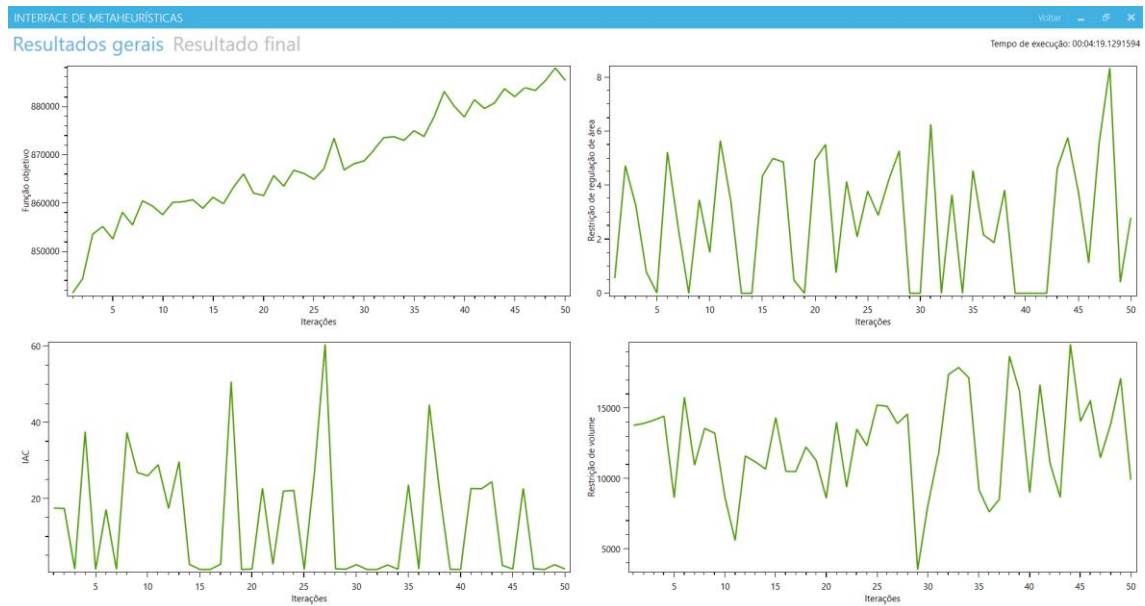


Figura 11 – Resultados gerais , função objetivo e o comportamento das penalidades de regulação , IAC e volumétrica, com o passar das iterações.



Figura 12- Resultados finais com área regulada, o volume e o IAC por período além do VPL acumulado.

### 3 - *Simulated annealing*(Recozimento Simulado)

No início dos anos 80, Kirkpatrick et al. (1983) e independentemente Cerný (1985), introduziram o conceito de recozimento em otimização combinatória. Originalmente este conceito foi inspirado por uma analogia entre o processo de recozimento de sólidos e o problema de resolver grandes problemas de otimização combinatória (AARTS et al., 2005). Para ilustrar a aplicação da meta-heurística SA utilizaremos o exemplo hipotético descrito no início do capítulo. A Figura 13 estão os parâmetros que devemos fornecer para executar o algoritmo.

A interface de configuração para a meta-heurística *Simulated Annealing* é apresentada em uma janela com o título "INTERFACE DE METAHEURÍSTICAS". No topo da janela, há uma barra de navegação com os links "Exportar instância", "Configurações" (destacado), e "Voltar", além de ícones para minimizar, maximizar e fechar a janela. O corpo da interface contém quatro campos de entrada com controles de incremento/decremento (+/-): "Temperatura inicial" com o valor 100000, "Temperatura final" com o valor 1000.00000, "Taxa de resfriamento" com o valor 0.950, e "Número de iterações" com o valor 100. Abaixo desses campos, há duas opções de seleção por rádio: "1-Opt" (desselecionada) e "2-Opt" (selecionada). No final da interface, há um botão "INICIAR HEURISTICA".

Figura 13– Parâmetros da meta-heurística *Simulated annealing*.

Os parâmetros a serem definidos são:

A temperatura inicial

A temperatura inicial tem um papel importante na convergência do algoritmo, temperaturas iniciais altas permitem uma busca aleatória pelo espaço de busca, enquanto temperaturas iniciais baixas tendem a convergir para a primeira solução encontrada.

- Temperatura Final

A temperatura final define a temperatura de parada do algoritmo.

- Taxa de resfriamento

A taxa de resfriamento utilizada é a geométrica onde a formula utilizada é a

$T = t_0 * tr$  onde:  $t_0$  é a temperatura inicial e  $tr$  é a taxa de resfriamento

- Número de iterações

É o número de vezes que o algoritmo irá iterar em uma certa temperatura antes de aplicar a taxa de resfriamento estabelecida pelo usuário.

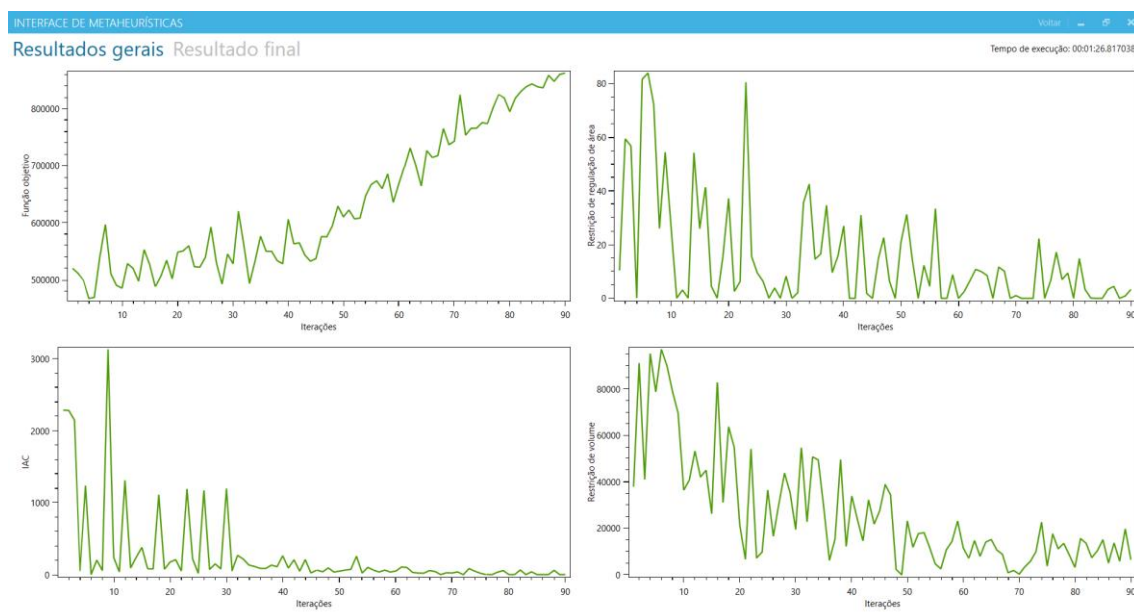


Figura 14- Resultados gerais , função objetivo e o comportamento das penalidades de regulação , IAC e volumétrica, com o passar das iterações.



Figura 15 - Resultados finais com a área regulada, o volume e o IAC por período além do VPL acumulado.

Analisando as figuras 13 e 14 observamos um valor de 862802.76 para a função de avaliação, com uma penalidade de 3,32 ha para a restrição de regulação, O IAC convergiu no valor de 1,5656 e todos os valores por período estavam entre 1,5 e 0,3, indicando que conseguiu atender a esta restrição, já para o volume a penalidade foi de 6.402. 12 m³ que ocorreram no período 1 e 2 e 10.

#### 4 - *Variable Neighborhood Search*(Pesquisa de vizinhança variável)



The image shows a web-based interface titled "INTERFACE DE METAHEURÍSTICAS". At the top, there is a navigation bar with links: "Exportar instância", "Configurações", and "Voltar". Below the navigation bar, the main area contains a label "Número de iterações" next to a numeric input field with the value "200" and increment/decrement buttons. At the bottom of the interface is a button labeled "INICIAR HEURISTICA".

Figura 16– Parâmetros da meta-heurística VNS.

Pesquisa de vizinhança variável (VNS) é uma meta-heurística, que explora sistematicamente a ideia de mudança de vizinhança, tanto em busca de mínimos locais ou na fuga de vales.

- Número de iterações.

O único parâmetro que precisamos definir é o número de iterações que o algoritmo vai realizar em cada vizinhança, para definir este parâmetro, testamos valores de 50, 100 até 500 iterações, e encontramos o valor de 200

Segundo VNS explora sistematicamente as seguintes observações:

- O mínimo local em relação a uma estrutura de vizinhança não é necessariamente o mínimo local de outra estrutura de vizinhança; um mínimo global é um mínimo local em relação a todas as possíveis estruturas de vizinhança; para muitos problemas, os mínimos locais em relação a uma vizinhança ou várias vizinhanças, são relativamente próximos uns dos outros.

Esta última observação, que é empírica, implica que um ótimo local frequentemente fornece algumas informações sobre o ótimo global.



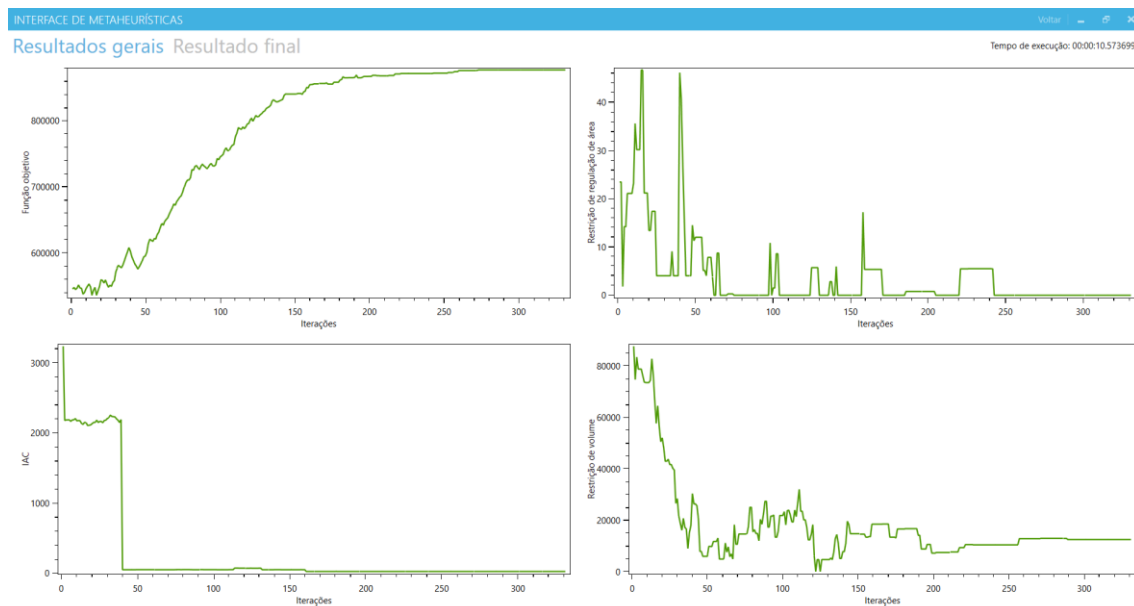


Figura 17- Resultados gerais , função objetivo e o comportamento das penalidades de regulação , IAC e volumétrica, com o passar das iterações.



Figura 18- Resultados finais com área regulada, o volume e o IAC por período além do VPL acumulado.

Analisando a figura 16 e 17, observamos que o tempo de processamento para esta instância foi de aproximadamente 11 segundos, com um valor da função de avaliação de 877101.05, não houve penalidade para a restrição de regulação, já para o volume, penalizamos 12.402 m<sup>3</sup>, que ocorrerem no ano 1 e ano 5, o IAC terminou com

um valor de 23.53 indicando que houve talhões adjacentes cortados no mesmo período, o IAC foi maior nos períodos 7 e 14.

Alguns testes foram realizados para determinar o valor ideal do número de iterações da VNS a tabela x é apresentado um resumo do número de iterações testados.

Tabela 8 – Resumo dos resultados das meta-heurísticas

Meta-heurística	Tempo de processamento	F.A	P.R	P.V.	P.A
VNS	10,48s	877,101.1	0.0	12,402.0	23.5
AG	1min e 11 seg	723,816.2	0.0	3,029.1	2.7
SA	1min e 26 seg	862,802.8	3.3	6,402.1	1.6
GRASP	05min e 19 seg	885,170.2	6.1	14,414.2	1.4

